

## TP4 et TP5 – Classification par SVM

Le but de ces TP est de tester une autre méthode de classification que celle du TP3, sur les mêmes données. Lancez le script `exercice_0`, qui affiche les caractéristiques de *compacité* et de *contraste* des images de l'ensemble d'apprentissage du TP3, correspondant aux classes « mélanomes » et « fibromes ». Ces données (`X_app` et `Y_app` dans `donnees_carac.mat`) ne sont pas *linéairement séparables*, mais il suffit d'en retirer quelques-unes pour qu'elles le deviennent (`X_app_filtre` et `Y_app_filtre` dans `donnees_carac_filtrees`).

### Contexte : données linéairement séparables - formulation « primale »

Soit  $\mathbf{X}_{\text{app}} = (\mathbf{x}_i)_{i \in \{1, \dots, n\}}$  un ensemble de  $n$  points du plan, constitué de deux classes  $\omega_1$  et  $\omega_2$  linéairement séparables, dont les *étiquettes*, notées  $y_i$ , valent 1 (pour les fibromes) ou  $-1$  (pour les mélanomes). L'équation cartésienne d'une droite  $\mathcal{D}$  du plan s'écrit :

$$\mathbf{w}^\top \mathbf{x} - c = 0 \quad (1)$$

où le vecteur non nul  $\mathbf{w}$  est orthogonal à  $\mathcal{D}$ , où  $\mathbf{x}$  désigne un point du plan et où  $c$  est un paramètre réel. Comme les deux demi-plans limités par  $\mathcal{D}$  sont définis par  $\mathcal{D}_1 = \{\mathbf{x} \in \mathbb{R}^2, \mathbf{w}^\top \mathbf{x} - c \leq 0\}$  et  $\mathcal{D}_2 = \{\mathbf{x} \in \mathbb{R}^2, \mathbf{w}^\top \mathbf{x} - c \geq 0\}$ , on peut imposer la contrainte suivante à toute droite  $\mathcal{D}$  constituant un *séparateur linéaire* de  $\omega_1$  et  $\omega_2$  :

$$y_i (\mathbf{w}^\top \mathbf{x}_i - c) > 0, \quad \forall i \in \llbracket 1, n \rrbracket \quad (2)$$

Parmi l'infinité de séparateurs linéaires vérifiant la contrainte (2), le SVM est celui qui maximise le carré de la distance minimale des points  $\mathbf{x}_i \in \mathbf{X}_{\text{app}}$  à  $\mathcal{D}$ , ce qui s'écrit :

$$\max_{\mathbf{w} \in \mathbb{R}^2, c \in \mathbb{R}} \left\{ \min_{\mathbf{x}_i \in \mathbf{X}_{\text{app}}} \left\{ \frac{(\mathbf{w}^\top \mathbf{x}_i - c)^2}{\|\mathbf{w}\|^2} \right\} \right\} \equiv \max_{\mathbf{w} \in \mathbb{R}^2, c \in \mathbb{R}} \left\{ \frac{1}{\|\mathbf{w}\|^2} \min_{\mathbf{x}_i \in \mathbf{X}_{\text{app}}} \{(\mathbf{w}^\top \mathbf{x}_i - c)^2\} \right\} \quad (3)$$

D'autre part, l'équation cartésienne (1) de  $\mathcal{D}$  est inchangée si  $\mathbf{w}$  et  $c$  sont multipliés par un même coefficient strictement positif. On peut donc choisir ce coefficient de telle sorte que, pour les points  $\mathbf{x}_i$  les plus proches de  $\mathcal{D}$ , qui sont appelés *vecteurs de support*, on ait exactement  $y_i (\mathbf{w}^\top \mathbf{x}_i - c) = 1$ . Dès lors, la contrainte (2) peut être réécrite :

$$y_i (\mathbf{w}^\top \mathbf{x}_i - c) - 1 \geq 0, \quad \forall i \in \llbracket 1, n \rrbracket \quad (4)$$

La valeur minimale de  $(\mathbf{w}^\top \mathbf{x}_i - c)^2$  vaut alors 1 et le problème (3) se simplifie en :

$$\max_{\mathbf{w} \in \mathbb{R}^2, c \in \mathbb{R}} \left\{ \frac{1}{\|\mathbf{w}\|^2} \right\} \equiv \min_{\mathbf{w} \in \mathbb{R}^2, c \in \mathbb{R}} \left\{ \frac{1}{2} \|\mathbf{w}\|^2 \right\} \quad (5)$$

qui constitue un problème de *minimisation quadratique*, sous les contraintes linéaires (4) de type inégalités. Ces problèmes de minimisation quadratique sous contraintes (de types égalités et/ou inégalités) peuvent être résolus de manière efficace par la fonction `quadprog` de Matlab (`help quadprog`). Les inconnues du problème doivent être concaténées en un vecteur  $\tilde{\mathbf{w}} = [\mathbf{w}^\top, c]^\top \in \mathbb{R}^3$ , et le problème reformulé sous forme « canonique » :

$$\begin{cases} \min_{\tilde{\mathbf{w}} \in \mathbb{R}^3} \left\{ \frac{1}{2} \tilde{\mathbf{w}}^\top \mathbf{H} \tilde{\mathbf{w}} \right\} \\ \text{s.c.} \quad \mathbf{A} \tilde{\mathbf{w}} \leq \mathbf{b} \end{cases} \quad (6)$$

Cette formulation pour résoudre le problème (3) est appelée formulation « primale ».

## Exercice 1 : données linéairement séparables - formulation « duale »

Une autre façon de résoudre le problème (4) + (5) consiste à introduire le *lagrangien* associé, qui dépend non seulement de  $\mathbf{w}$  et de  $c$ , mais également de  $n$  *multiplicateurs de Lagrange*, notés  $\alpha_i \in \mathbb{R}$ , correspondant aux  $n$  contraintes linéaires (4) :

$$\begin{aligned}\mathcal{L}(\mathbf{w}, c, \alpha_1, \dots, \alpha_n) &= \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^n \alpha_i [y_i (\mathbf{w}^\top \mathbf{x}_i - c) - 1] \\ &= \frac{1}{2} \mathbf{w}^\top \mathbf{w} - \mathbf{w}^\top \sum_{i=1}^n \alpha_i y_i \mathbf{x}_i + c \sum_{i=1}^n \alpha_i y_i + \sum_{i=1}^n \alpha_i\end{aligned}\quad (7)$$

Comme les contraintes (4) sont de type  $\geq 0$ , les multiplicateurs  $\alpha_i$  doivent vérifier la contrainte suivante :

$$\alpha_i \geq 0, \quad \forall i \in \llbracket 1, n \rrbracket \quad (8)$$

De plus, les seuls indices  $i$  pour lesquels  $\alpha_i > 0$  sont ceux des vecteurs de support, là où  $y_i (\mathbf{w}^\top \mathbf{x}_i - c) - 1 = 0$ . Les conditions d'optimalité du premier ordre de  $\mathcal{L}$ , relativement à  $\mathbf{w}$  et à  $c$ , s'écrivent, respectivement :

$$\mathbf{w} = \sum_{i=1}^n \alpha_i y_i \mathbf{x}_i \quad (9)$$

$$\sum_{i=1}^n \alpha_i y_i = 0 \quad (10)$$

La *fonction duale* du lagrangien  $\mathcal{L}$ , qui ne dépend que des  $\alpha_i$ , s'obtient en réinjectant (9) et (10) dans (7) :

$$\bar{\mathcal{L}}(\alpha_1, \dots, \alpha_n) = -\frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i y_i \mathbf{x}_i^\top \mathbf{x}_j y_j \alpha_j + \sum_{i=1}^n \alpha_i \quad (11)$$

Cette fonction étant quadratique mais concave, il faut rechercher son maximum en résolvant un nouveau problème d'optimisation quadratique sous contraintes : contraintes (10) de type égalités + contraintes (8) de type inégalités. En introduisant le vecteur  $\boldsymbol{\alpha} = [\alpha_1, \dots, \alpha_n]^\top$ , la forme canonique de ce problème s'écrit :

$$\begin{cases} \max_{\boldsymbol{\alpha} \in \mathbb{R}^n} \left\{ -\frac{1}{2} \boldsymbol{\alpha}^\top \mathbf{H} \boldsymbol{\alpha} + \mathbf{f}^\top \boldsymbol{\alpha} \right\} \\ \text{s.c.} \left\{ \begin{array}{l} \mathbf{A}_{\text{eq}} \boldsymbol{\alpha} = 0 \\ \boldsymbol{\alpha} \geq \mathbf{0}_{\mathbb{R}^n} \end{array} \right. \end{cases} \quad (12)$$

Écrivez la fonction `estim_param_SVM_dual`, appelée par le script `exercice_1_dual`, permettant de résoudre le problème (12) par un appel à la fonction `quadprog`.

### Conseils de programmation :

- Attention au fait que (12) est un problème de *maximisation*, et non de minimisation.
- Une fois trouvés les multiplicateurs de Lagrange, les vecteurs de support  $\mathbf{X}_{\text{VS}}$  sont faciles à identifier, puisque ce sont les points  $\mathbf{x}_i$  dont l'indice  $i$  est tel que  $\alpha_i > 0$  (utilisez ici un seuil à  $10^{-6}$  pour ce test).
- Le vecteur  $\mathbf{w}$  se déduit de (9), où la somme peut être restreinte aux indices des vecteurs de support.
- Enfin, pour calculer  $c$ , il suffit par exemple de prendre un vecteur de support  $\mathbf{x}_i$  d'étiquette  $y_i$ , qui vérifie l'égalité  $y_i (\mathbf{w}^\top \mathbf{x}_i - c) - 1 = 0$ , soit  $c = \mathbf{w}^\top \mathbf{x}_i - y_i$ .
- Le dernier paramètre de sortie de la fonction est le code de retour de `quadprog` (« exitflag »), qui vaut 1 lorsque la résolution converge. Vérifiez que cela n'est pas le cas avec les données  $\mathbf{X}_{\text{app}}$  et  $\mathbf{Y}_{\text{app}}$ .

Complétez ensuite la fonction `classification_SVM` qui doit classer les individus  $\mathbf{x}_i \in \mathbf{X}_{\text{app}}$  à partir de l'équation (2). Afin de se retrouver avec des valeurs 1 et -1 dans le vecteur de prédiction  $\mathbf{Y}_{\text{pred}}$ , il suffit alors de résoudre :

$$y_i = \text{signe}(\mathbf{w}^\top \mathbf{x}_i - c), \quad \forall i \in \llbracket 1, n \rrbracket \quad (13)$$

Lancez enfin le script `exercice_1_dual` et vérifiez que vous retrouvez bien le même séparateur linéaire pour les formulations primale et duale sur les deux figures.

## Exercice 2 : données non linéairement séparables - noyau gaussien

Il est rare que des données non filtrées soient linéairement séparables. Pour pallier ce problème, on peut appliquer aux points  $\mathbf{x}_i$  une transformation non linéaire, notée  $\phi$ , de  $\mathbb{R}^2$  dans un espace  $\mathcal{E}$  de plus grande dimension. Dans cet espace, on cherche un *hyperplan* séparateur, ayant pour équation cartésienne :

$$\mathbf{w}^\top \phi(\mathbf{x}) - c = 0 \quad (14)$$

où  $\mathbf{w} \in \mathcal{E}$  et  $c \in \mathbb{R}$ , devant vérifier les contraintes suivantes :

$$y_i (\mathbf{w}^\top \phi(\mathbf{x}_i) - c) > 0, \quad \forall i \in \llbracket 1, n \rrbracket \quad (15)$$

La formulation duale présente alors un avantage important sur la formulation primale car l'extension du problème (6) nécessite de changer d'espace de recherche, puisque l'inconnue  $\mathbf{w} \in \mathcal{E}$ , alors que l'inconnue  $\alpha \in \mathbb{R}^n$  du problème (12) est indépendante de l'espace  $\mathcal{E}$ . L'extension de la fonction duale (11) s'écrit dorénavant :

$$\bar{\mathcal{L}}(\alpha_1, \dots, \alpha_n) = -\frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i y_i \phi(\mathbf{x}_i)^\top \phi(\mathbf{x}_j) y_j \alpha_j + \sum_{i=1}^n \alpha_i \quad (16)$$

qui fait bien intervenir deux vecteurs de  $\mathcal{E}$ , mais **seulement par le biais de leur produit scalaire**  $\phi(\mathbf{x}_i)^\top \phi(\mathbf{x}_j)$ . Le « coup du noyau » (*kernel trick*), qui n'est pas une spécificité des SVM, consiste à remplacer ce produit scalaire par une fonction  $K$ , appelée *fonction noyau*, ce qui permet de réécrire (16) sous la forme suivante :

$$\bar{\mathcal{L}}(\alpha_1, \dots, \alpha_n) = -\frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i y_i K(\mathbf{x}_i, \mathbf{x}_j) y_j \alpha_j + \sum_{i=1}^n \alpha_i \quad (17)$$

Le noyau qui sera utilisé par la suite est le *noyau gaussien*, où le paramètre  $\sigma$  représente un écart-type :

$$K(\mathbf{x}_i, \mathbf{x}_j) = \exp \left( -\frac{\|\mathbf{x}_i - \mathbf{x}_j\|^2}{2\sigma^2} \right) \quad (18)$$

Écrivez la fonction `estim_param_SVM_noyau`, permettant de rechercher le maximum de la fonction  $\bar{\mathcal{L}}$ , définie par (17) et (18), sous les mêmes contraintes que celles du problème (12). Seule la matrice  $\mathbf{H}$  sera modifiée.

### Conseils de programmation :

- Commencez par calculer la *matrice de Gram*, dont l'élément courant  $G(i, j)$  est égal à  $K(\mathbf{x}_i, \mathbf{x}_j)$ .
- Comme la fonction  $\phi$  n'est pas explicitement connue,  $\mathbf{w}$  ne peut pas être calculé explicitement. D'ailleurs, il ne fait pas partie des paramètres de sortie de la fonction `estim_param_SVM_noyau`.
- En revanche,  $c$  peut être calculé en reportant l'expression (9) de  $\mathbf{w}$  dans l'égalité  $y_i (\mathbf{w}^\top \mathbf{x}_i - c) - 1 = 0$  et en utilisant à nouveau le noyau  $K$  pour remplacer les produits scalaires, et où la somme peut être restreinte aux indices  $j$  des vecteurs de support :

$$c = \sum_{j=1}^n \alpha_j y_j K(\mathbf{x}_j, \mathbf{x}_i) - y_i \quad (19)$$

Complétez ensuite la fonction `classification_SVM_avec_noyau` qui doit classer les individus  $\mathbf{x}_i \in \mathbf{X}_{\text{app}}$  à partir de l'équation (15). Afin de se retrouver avec des valeurs 1 et  $-1$  dans le vecteur de prédiction  $\mathbf{Y}_{\text{pred}}$ , il suffit alors de résoudre :

$$y_i = \text{signe} \left( \sum_{j=1}^n \alpha_j y_j K(\mathbf{x}_j, \mathbf{x}_i) - c \right), \quad \forall i \in \llbracket 1, n \rrbracket \quad (20)$$

Remplissez enfin la fonction `maximisation_classification_SVM_noyau` qui doit, entre autres, retourner le paramètre  $\sigma^*$  qui maximise la classification de *l'ensemble de test*, suite à une estimation des paramètres du SVM sur *l'ensemble d'apprentissage*. Lancez successivement le script `exercice_2` pour obtenir les courbes d'optimisation, puis le script `exercice_2bis` pour visualiser la classification optimale.

### Exercice 3 : données non linéairement séparables - marge souple

Une autre manière de classer des données non linéairement séparables par SVM utilise le concept de « marge souple » (*soft margin*), qui revient à assouplir les contraintes  $y_i (\mathbf{w}^\top \mathbf{x}_i - c) - 1 \geq 0$ . Cela peut se faire en introduisant de nouvelles variables, appelées « variables de ressort » et notées  $\xi_i$  pour modifier la borne inférieure de la façon suivante :

$$y_i (\mathbf{w}^\top \mathbf{x}_i - c) - 1 \geq -\xi_i, \quad \forall i \in \llbracket 1, n \rrbracket \quad (21)$$

avec les contraintes suivantes pour être moins stricte que  $\geq 0$  dans l'inégalité (21) :

$$\xi_i \geq 0, \quad \forall i \in \llbracket 1, n \rrbracket \quad (22)$$

En prenant en compte les deux contraintes précédentes, le nouveau problème prend alors la forme :

$$\min_{\substack{\mathbf{w} \in \mathbb{R}^2, c \in \mathbb{R} \\ (\xi_1, \dots, \xi_n) \in \mathbb{R}^n}} \left\{ \frac{1}{2} \|\mathbf{w}\|^2 + \lambda \sum_{i=1}^n \xi_i \right\} \quad (23)$$

où  $\lambda$  est un paramètre permettant de contrôler le poids associé au terme de régularisation  $\sum_{i=1}^n \xi_i$  dans la fonction à minimiser. La formulation duale de ce problème nécessite d'introduire  $n$  nouveaux multiplicateurs  $\beta_i$  dans le lagrangien  $\mathcal{L}$ , correspondant aux nouvelles contraintes (22) :

$$\begin{aligned} \mathcal{L}_2(\mathbf{w}, c, \alpha_1, \dots, \alpha_n, \beta_1, \dots, \beta_n) &= \frac{1}{2} \|\mathbf{w}\|^2 + \lambda \sum_{i=1}^n \xi_i - \sum_{i=1}^n \alpha_i [y_i (\mathbf{w}^\top \mathbf{x}_i - c) - 1 + \xi_i] - \sum_{i=1}^n \beta_i \xi_i \\ &= \frac{1}{2} \mathbf{w}^\top \mathbf{w} - \mathbf{w}^\top \sum_{i=1}^n \alpha_i y_i \mathbf{x}_i + c \sum_{i=1}^n \alpha_i y_i + \sum_{i=1}^n \alpha_i + \sum_{i=1}^n (\lambda - \alpha_i - \beta_i) \xi_i \end{aligned} \quad (24)$$

Les contraintes sur les nouveaux multiplicateurs sont similaires à celles des  $\alpha_i$ , car (22) est de type « supérieur ou égal » :

$$\beta_i \geq 0, \quad \forall i \in \llbracket 1, n \rrbracket \quad (25)$$

Les conditions d'optimalité du premier ordre de  $\mathcal{L}_2$ , relativement aux variables  $\xi_i$ , s'écrivent simplement :

$$\lambda - \alpha_i - \beta_i = 0, \quad \forall i \in \llbracket 1, n \rrbracket \quad (26)$$

en complément des autres conditions d'optimalité introduites dans la formulation duale. Avec les inégalités  $\alpha_i \geq 0$  issues de la formulation duale, ajoutée à (25) et (26), la contrainte d'inégalité de (24) se simplifie en :

$$0 \leq \alpha_i \leq \lambda, \quad \forall i \in \llbracket 1, n \rrbracket \quad (27)$$

La forme canonique du problème d'optimisation (24) devient alors :

$$\begin{cases} \max_{\alpha \in \mathbb{R}^n} \left\{ -\frac{1}{2} \alpha^\top \mathbf{H} \alpha + \mathbf{f}^\top \alpha \right\} \\ \text{s.c.} \begin{cases} \mathbf{A}_{\text{eq}} \alpha = 0 \\ \alpha \geq \mathbf{0}_{\mathbb{R}^n} \\ \alpha \leq \lambda \mathbf{1}_{\mathbb{R}^n} \end{cases} \end{cases} \quad (28)$$

Écrivez la fonction `estim_param_SVM_marge`, permettant de rechercher le maximum de la fonction  $\bar{\mathcal{L}}$ , définie par (24), sous les contraintes décrites dans (28).

#### Conseils de programmation :

- Les vecteurs de support  $\mathbf{X}_{\text{VS}}$  sont encore les points  $\mathbf{x}_i$  d'indice  $i$  tel que  $\alpha_i > 0$ , et le vecteur  $\mathbf{w}$  se déduit encore de (9), en restreignant la somme aux indices des vecteurs de support.
- En revanche, pour calculer  $c$ , **on ne doit pas utiliser n'importe quel vecteur de support !** Pour un vecteur de support d'indice  $i$  tel que  $\alpha_i < \lambda$ , d'après (26), le multiplicateur associé à la variable ressort  $\xi_i$  vérifie  $\beta_i > 0$ . Par conséquent, cette variable doit vérifier  $\xi_i = 0$ . Comme  $\mathbf{x}_i$  est un vecteur de support, on sait également que (21) est une égalité, donc on peut affirmer que  $y_i (\mathbf{w}^\top \mathbf{x}_i - c) - 1 = 0$ .

La classification du SVM avec marge souple s'effectue avec la fonction `classification_SVM` que vous avez codée précédemment. Remplissez enfin la fonction `maximisation_classification_SVM_marge` qui doit, entre autres, retourner le paramètre  $\lambda^*$  qui maximise la classification de *l'ensemble de test*, suite à une estimation des paramètres du SVM sur *l'ensemble d'apprentissage*. Lancez successivement le script `exercice_3` pour obtenir les courbes d'optimisation, puis le script `exercice_3bis` pour visualiser la classification optimale.

## Exercice 4 - combinaison du noyau et de la marge souple (facultatif)

Pour obtenir le meilleur des deux méthodes, il est possible de les combiner. En remplaçant le produit scalaire  $\mathbf{x}_i^\top \mathbf{x}_j$  par l'expression avec le noyau  $K(\mathbf{x}_i, \mathbf{x}_j)$  et en ajoutant la régularisation sur les variables de ressort  $\xi_i$ , on se retrouve à nouveau à résoudre un problème (28). À partir des fonctions `estim_param_SVM_noyau` et `estim_param_SVM_marge`, complétez la fonction `estim_param_SVM_noyau_marge` qui doit trouver les paramètres pour le problème combiné.

Par la suite, en utilisant la fonction de classification `classification_SVM_avec_noyau`, Remplissez enfin la fonction `maximisation_classification_SVM_noyau_marge` qui doit, entre autres, retourner le couple de paramètres  $(\sigma^*, \lambda^*)$  qui maximise la classification de *l'ensemble de test*, suite à une estimation des paramètres du SVM sur *l'ensemble d'apprentissage*. Lancez successivement le script `exercice_4` pour obtenir les courbes d'optimisation, puis le script `exercice_4bis` pour visualiser la classification optimale.